

Multimodal FuseLinker with Auxiliary PPR Diffusion for Biomedical Knowledge Graph Link Prediction

Pham Van Hai, Le Van Thanh, Le Tien Thuc

Abstract Dự đoán liên kết trên đồ thị tri thức y sinh (biomedical knowledge graph, BKG) là bài toán then chốt phục vụ tái định hướng thuốc (drug repurposing) và khám phá quan hệ thuốc-bệnh-gene. Phương pháp nền tảng FuseLinker [1] khai thác mạng nơ-ron tích chập đồ thị quan hệ (R-GCN [3]) kết hợp với hai nguồn đặc trưng bổ sung cho mỗi nút: biểu diễn ngữ nghĩa văn bản từ mô hình ngôn ngữ y sinh và biểu diễn tri thức miền trong không gian hyperbolic/Poincaré. Tuy nhiên, FuseLinker vẫn còn hai hạn chế: cơ chế hợp nhất hai nguồn đặc trưng dựa trên trung bình có trọng số cố định, và việc lan truyền chủ yếu diễn ra trên đồ thị quan hệ gốc theo từng bước cục bộ. Trong nghiên cứu này, chúng tôi đề xuất một phiên bản nâng cấp kế thừa FuseLinker và tích hợp ý tưởng mạng phụ trợ từ HGDC [2]. Thứ nhất, mô hình thay cơ chế trộn cố định bằng một cổng hợp nhất học được (gated fusion), điều phối động sự đóng góp của đặc trưng văn bản và đặc trưng tri thức miền theo từng nút. Thứ hai, mô hình xây dựng một mạng phụ trợ bằng Personalized PageRank (PPR), trong đó ma trận tương đồng cấu trúc được làm thưa bằng ngưỡng cắt và giữ lại top-k láng giềng cho mỗi nút; một nhánh PPR-GCN chạy song song với nhánh R-GCN để thu thập tín hiệu cấu trúc toàn cục, sau đó được hợp nhất bằng cổng học được thứ hai. Ngoài ra, mô hình được tăng cường bằng các khối residual, pre-LayerNorm, Jumping Knowledge và residual embedding theo định danh nút nhằm giảm over-smoothing và ổn định huấn luyện. Toàn bộ cải tiến giữ nguyên giao diện huấn luyện/đánh giá của FuseLinker, bao gồm bộ chấm điểm DistMult, negative sampling và các độ đo MR, MRR, Hits@K, AUROC. Kết quả thực nghiệm trên bốn BKG cho thấy mô hình đề xuất cải thiện nhất quán ở các độ đo xếp hạng, đặc biệt trên các đồ thị khó và nhiễu như ADInt và Hetionet.

Keywords: biomedical knowledge graph; link prediction; drug repurposing; FuseLinker; HGDC; R-GCN; Personalized PageRank; gated fusion.

1. Introduction

Đồ thị tri thức y sinh (biomedical knowledge graph, BKG) như Hetionet [4] biểu diễn tri thức y sinh dưới dạng một mạng lưới không đồng nhất, trong đó các nút là các thực thể sinh học hoặc lâm sàng như thuốc, bệnh, gene, triệu chứng, pathway, tác dụng phụ và lớp được lý; còn các cạnh biểu diễn nhiều kiểu quan hệ khác nhau giữa các thực thể đó. Trên cấu trúc này, dự đoán liên kết (link prediction) trở thành một bài toán trung tâm vì nhiều quan hệ đúng trong BKG chưa được quan sát đầy đủ hoặc chưa được khám phá trong thực nghiệm.

Trong bối cảnh tái định hướng thuốc (drug repurposing), dự đoán liên kết có thể được dùng để suy luận các cạnh còn thiếu giữa thuốc và bệnh, từ đó đề xuất các chỉ định điều trị tiềm năng với chi phí thấp hơn nhiều so với quy trình thử nghiệm sinh học truyền thống. Ngoài ra, link prediction trên BKG còn hỗ trợ phát hiện giả thuyết y sinh, nhận diện quan hệ gene-bệnh, phân tích tương tác thuốc-gene, dự đoán tác dụng phụ và ưu tiên các ứng viên cần kiểm chứng trong nghiên cứu lâm sàng.

Tuy nhiên, BKG thường thừa, nhiễu và bất toàn. Một số quan hệ bị thiếu vì dữ liệu nguồn chưa được tích hợp đầy đủ, trong khi nhiều quan hệ khác thật sự chưa được biết đến. Do đó, nếu chỉ dựa vào cấu trúc topo quan sát được, mô hình có thể không học được biểu diễn nút đủ giàu ngữ nghĩa. Mặt khác, nhiều thực thể y sinh có thông tin văn bản không đồng đều: một số thực thể có mô tả phong phú trong y văn, trong khi số khác chỉ có tên ngắn hoặc mã định danh. Tri thức miền từ ontology lại có thể mạnh riêng trong việc biểu diễn quan hệ phân cấp, nhưng không phải mọi thực thể đều có ánh xạ ontology rõ ràng.

FuseLinker [1] là một hướng tiếp cận quan trọng cho vấn đề này vì mô hình kết hợp đồng thời ba nguồn tín hiệu: embedding văn bản từ mô hình ngôn ngữ, embedding tri thức miền từ UMLS/Poincaré và biểu diễn cấu trúc học bằng R-GCN. Cách thiết kế này giúp mô hình không chỉ dựa vào cạnh quan sát được, mà còn tận dụng ngữ nghĩa tên thực thể và quan hệ phân cấp trong ontology y sinh. Đây là nền tảng trực tiếp để bài viết này xây dựng một phiên bản nâng cấp, tập trung vào hai điểm: hợp nhất đặc trưng thích ứng hơn và bổ sung tín hiệu cấu trúc toàn cục.

Mặc dù hiệu quả, kiến trúc FuseLinker vẫn còn hai hạn chế đáng chú ý. Thứ nhất, cơ chế hợp nhất đặc trưng còn cứng nhắc. FuseLinker kết hợp đặc trưng văn bản và đặc trưng tri thức miền bằng một trọng số trộn cố định dùng chung cho toàn bộ đồ thị. Cách làm này đơn giản, dễ tái lập và ổn định, nhưng không phản ánh được thực tế rằng mức độ tin cậy của từng nguồn thay đổi theo từng loại thực thể. Ví dụ, một nút thuốc hoặc bệnh có tên và mô tả văn bản rõ ràng có thể cần ưu tiên nguồn văn bản; trong khi một lớp bệnh hoặc một semantic type nằm trong hệ phân cấp ontology rõ ràng có thể cần ưu tiên tri thức miền.

Thứ hai, phạm vi lan truyền thông tin của R-GCN chủ yếu nằm ở mức cục bộ. Với số lớp nông, thường chỉ một đến hai lớp để tránh hiện tượng over-smoothing, mỗi nút chỉ tổng hợp được tín hiệu từ vùng láng giềng gần. Trong mạng y sinh, các thực thể có vai trò chức năng tương tự có thể không nối trực tiếp nhưng vẫn nằm trong cùng vùng cấu trúc rộng thông qua nhiều nút trung gian. Nếu chỉ lan truyền theo cạnh quan hệ gốc, mô hình dễ bỏ sót các quan hệ gần

cấu trúc toàn cục giữa những nút cách xa nhau.

Để giải quyết hai hạn chế trên, bài viết này kế thừa khung FuseLinker và tích hợp ý tưởng mạng phụ trợ đã được chứng minh hiệu quả trong HGDC [2]. HGDC sử dụng khuếch tán đồ thị, cụ thể là Personalized PageRank, để tạo một mạng phụ trợ phản ánh độ gần cấu trúc giữa các nút trong mạng sinh học. Mạng phụ trợ này giúp kết nối các nút có bối cảnh cấu trúc tương tự, ngay cả khi chúng không nối trực tiếp trong mạng gốc.

Trên cơ sở đó, mô hình đề xuất có ba nhóm cải tiến chính. Thứ nhất, mô hình thay cơ chế hợp nhất cố định bằng cổng học được (gated fusion), cho phép điều chỉnh đóng góp của embedding văn bản và embedding tri thức miền theo từng nút và từng chiều ẩn. Thứ hai, mô hình bổ sung một nhánh PPR-GCN chạy song song với nhánh R-GCN. Nhánh R-GCN giữ vai trò học quan hệ cục bộ có kiểu cạnh, còn nhánh PPR-GCN bổ sung tín hiệu gần cấu trúc toàn cục từ mạng phụ trợ. Thứ ba, backbone được tăng cường bằng residual block, pre-LayerNorm, Jumping Knowledge và embedding định danh nút nhằm ổn định huấn luyện và hạn chế làm trơn quá mức.

Một điểm quan trọng trong thiết kế là toàn bộ cải tiến vẫn giữ nguyên giao diện huấn luyện và đánh giá của FuseLinker, bao gồm bộ chấm điểm DistMult, negative sampling và các độ đo MR, MRR, Hits@K, AUROC. Nhờ đó, mô hình đề xuất có thể được so sánh công bằng với baseline và có thể bật/tắt từng thành phần để phân tích ablation.

Để đánh giá khả năng tổng quát hóa của mô hình đề xuất trên các mức độ thừa, nhiễu và khó khác nhau của BKG, nghiên cứu sử dụng bốn bộ dữ liệu đại diện: Hetionet, SuppKG, KEGG50K và ADInt. Bốn bộ dữ liệu này bao phủ nhiều kiểu đồ thị khác nhau: một KG đa miền phục vụ tái định hướng thuốc, một KG tập trung quan hệ được lý, một KG pathway-gene gần bão hòa, và một KG lớn trích xuất từ y văn về tương tác thuốc bất lợi.

Hetionet [4] là đồ thị tri thức y sinh đa nguồn do Himmelstein và cộng sự xây dựng, tích hợp nhiều cơ sở dữ liệu công khai như DrugBank, ChEMBL, UMLS, Gene Ontology, Reactome và WikiPathways. Phiên bản đầy đủ chứa khoảng 47,031 thực thể thuộc 11 loại và 24 loại quan hệ có hướng, với hơn 2.25 triệu cạnh. Trong nghiên cứu này, biến thể lọc Gene/Compound/Disease gồm 19,930 thực thể, 13 quan hệ và 562,106 cạnh được dùng cho thí nghiệm liên quan tới tái định hướng thuốc.

SuppKG [5] được xây dựng cho các bài toán liên quan tới thuốc, thực phẩm bổ sung và quan hệ được lý, tích hợp các nguồn y văn như SemMedDB, CTD và DrugCentral. Bộ dữ liệu có độ khó trung bình: quan hệ thưa hơn Hetionet, nhiều thực thể có thông tin văn bản hữu ích nhưng vị trí trong ontology không phải lúc nào cũng rõ. Đây là kịch bản phù hợp để đánh giá khả năng tận dụng nguồn văn bản.

KEGG50K [7] là mẫu con của KEGG, tập trung vào pathway, gene, thuốc và bệnh. Bộ dữ liệu này có cấu trúc tương đối rõ và baseline thường đạt MRR rất cao, do đó phù hợp để kiểm tra hiệu ứng trần: mô hình nâng cấp có cải thiện thêm được hay ít nhất có giữ được hiệu năng khi cấu trúc topo đã rất mạnh hay không.

ADInt [6] là đồ thị lớn trích xuất từ y văn theo phong cách SemMedDB, gồm nhiều quan hệ ngữ nghĩa như tương tác, đồng xuất hiện và điều trị. ADInt có số lượng thực thể lớn, phân bố quan hệ lệch và nhiều liên kết ngữ nghĩa rộng, nên là kịch bản khó để kiểm tra tác

Bảng 1: Tổng hợp đặc điểm chính của bốn bộ dữ liệu BKG dùng trong thực nghiệm.

Dataset	Quy mô nút/cạnh	Kiểu quan hệ	Độ khó	Vai trò trong đánh giá
Hetionet	47,031 nút, 2,250,197 cạnh; biến thể lọc 19,930 nút, 562,106 cạnh	Gene, Compound, Disease và nhiều quan hệ y sinh	Trung bình-khó	Đánh giá khả năng học trên BKG đa miền, nhiều loại nút, nhiều quan hệ và cấu trúc phong phú.
SuppKG	45,158 thực thể, 244,788 triple train, valid/test khoảng 30,000 mỗi tập	Quan hệ được lý và y văn như treats, causes, interacts	Trung bình	Kiểm tra khả năng tận dụng text embedding khi nhiều thực thể có mô tả văn bản nhưng ontology mỏng.
KEGG50K	Khoảng 50,000 node, 57,080 triple train	Pathway-gene-drug-disease	Dễ hơn/gần bảo hòa	Kiểm tra hiệu ứng trần và độ an toàn của mô hình nâng cấp khi baseline đã rất cao.
ADInt	162,212 thực thể, 1,294,814 cạnh, 15 quan hệ	Quan hệ ngữ nghĩa y văn, tương tác thuốc bất lợi	Khó	Đánh giá khả năng xử lý đồ thị lớn, nhiều, phân bố quan hệ lệch và nhiều liên kết yếu.

dụng của nhánh khuếch tán PPR trong việc lọc và bổ sung tín hiệu cấu trúc toàn cục.

Tóm lại, các đóng góp chính của nghiên cứu gồm:

- Chỉ ra và phân tích hai hạn chế của FuseLinker: cơ chế hợp nhất đặc trưng cố định và phạm vi lan truyền thông tin chủ yếu ở mức cục bộ.
- Viết lại phần Introduction theo hướng không đưa công thức vào phần mở đầu, giúp động lực nghiên cứu, hạn chế của baseline và ý tưởng đề xuất được trình bày rõ ràng hơn.
- Bổ sung phần Related Work dựa trên FuseLinker 2024 và HGDC 2023, đồng thời chuyển các công thức nền tảng từ phần mở đầu sang phần Related Work để bố cục bài báo hợp lý hơn.
- Đề xuất cơ chế gated fusion cho cả giai đoạn trộn đặc trưng đầu vào và giai đoạn trộn hai nhánh đồ thị.
- Tích hợp mạng phụ trợ PPR theo HGDC vào khung FuseLinker để bổ sung tín hiệu cấu trúc toàn cục, kèm các bước làm thưa bằng ngưỡng và top-k để khả thi trên đồ thị lớn.
- Giữ nguyên quy trình huấn luyện và đánh giá của FuseLinker, đồng thời thực nghiệm trên bốn BKG với đầy đủ bảng kết quả MR, MRR, Hits@K và AUROC.

2. Related Work

2.1. Dự đoán liên kết trên biomedical knowledge graph

Dự đoán liên kết trên KG, hay knowledge graph completion, thường được mô hình hóa như bài toán xếp hạng các triple đúng cao hơn triple sai. Các phương pháp cổ điển gồm heuristic dựa trên lân cận, random walk, knowledge graph embedding như TransE, DistMult, ComplEx, và các mô hình GNN như GCN, GAT hoặc R-GCN. Trong BKG, bài toán này có ý nghĩa thực tiễn rõ rệt vì một thuốc có thể điều trị nhiều bệnh, một bệnh có thể liên quan tới nhiều gene, và một gene có thể tham gia nhiều pathway hoặc cơ chế bệnh khác nhau.

Khác với KG tổng quát, BKG vừa giàu cấu trúc miền y sinh vừa thiếu mô tả văn bản ở một số thực thể. Vì vậy, mô hình chỉ dựa vào topology dễ bỏ qua ngữ nghĩa thực thể, còn mô hình chỉ dựa vào text dễ mất thông tin quan hệ đa bước trên đồ thị. Xu hướng gần đây là kết hợp LLM với GNN: LLM đóng vai trò bộ tăng cường đặc trưng văn bản, còn GNN học cấu trúc quan hệ. FuseLinker là đại diện tiêu biểu cho hướng này trong BKG, còn HGDC cung cấp một hướng bổ sung bằng khuếch tán đồ thị để xử lý tín hiệu heterophilic trong mạng sinh học.

2.2. FuseLinker: hợp nhất văn bản, tri thức miền và cấu trúc

FuseLinker [1] là framework dự đoán liên kết cho BKG gồm ba mô-đun chính. Mô-đun thứ nhất sinh text embedding cho nút bằng các mô hình ngôn ngữ có thể trích embedding, bao gồm BERT, PubMedBERT, Flan-T5, LLaMA2 và PMC-LLaMA. Mô-đun thứ hai học domain knowledge embedding từ UMLS Semantic Network bằng mô hình Poincaré đa quan hệ, phù hợp với quan hệ phân cấp trong ontology y sinh. Mô-đun thứ ba hợp nhất hai embedding này để khởi tạo R-GCN và dùng DistMult để chấm điểm triple.

Trong FuseLinker, hai nguồn đặc trưng được trộn bằng một trọng số cố định:

$$h = (1 - w)h_{\text{domain}} + wh_{\text{text}}, \quad w \in [0, 1]. \quad (1)$$

Công thức này là một baseline rõ ràng và dễ tái lập, nhưng đồng thời tạo ra hạn chế quan trọng: cùng một hệ số w được dùng cho mọi nút và mọi chiều đặc trưng. Trong BKG không đồng nhất, điều này có thể làm giảm khả năng tận dụng tính bổ trợ giữa text embedding và domain embedding. Chính hạn chế này là động lực trực tiếp cho cơ chế gated fusion của mô hình đề xuất.

2.3. HGDC: khuếch tán đồ thị và mạng phụ trợ PPR

HGDC [2] được đề xuất cho bài toán nhận diện cancer driver genes trong mạng sinh học có tính heterophily. Trong các mạng này, hai

nút nối trực tiếp chưa chắc cùng lớp hoặc có đặc trưng giống nhau; ngược lại, các gene có vai trò chức năng tương tự có thể cách nhau nhiều bước. Vì vậy, nếu GCN chỉ tổng hợp thông tin từ lân cận trực tiếp, đặc trưng phân biệt của gene quan trọng có thể bị làm trơn bởi các láng giềng khác loại.

HGDC giải quyết vấn đề này bằng cách dùng Personalized PageRank để sinh một mạng phụ trợ phản ánh độ gần cấu trúc toàn cục:

$$\mathbf{s}_i = cM\mathbf{s}_i + (1 - c)\mathbf{e}_i, \quad (2)$$

$$\text{PPR}(\mathbf{s}_i) = (1 - c)(I_N - cM)^{-1}\mathbf{e}_i. \quad (3)$$

Khi thay $\mathbf{e}_i$ bằng ma trận đơn vị I_N , ta thu được ma trận tương đồng cấu trúc và đồ thị phụ trợ:

$$S = (1 - c)(I_N - cM)^{-1}, \quad (4)$$

$$\mathcal{G}_{\text{ppr}} = \{(v, u) : \tilde{S}_{vu} > 0\}. \quad (5)$$

Trong đó c là damping factor, M là ma trận chuyển tiếp chuẩn hóa, và S_{ij} đo độ gần cấu trúc giữa nút i và nút j . Vì S thường dày đặc, HGDC làm thưa bằng ngưỡng cắt để tạo mạng phụ trợ khả thi về bộ nhớ. Ý tưởng này phù hợp với BKG: nhiều thực thể y sinh có thể liên quan gián tiếp qua pathway, gene, tác dụng phụ hoặc cơ chế bệnh, và các quan hệ gián tiếp đó có thể bổ sung cho cạnh quan hệ gốc.

2.4. Vị trí của mô hình đề xuất so với hai công trình nền

Mô hình đề xuất kết hợp hai hướng bổ sung nhau. Từ FuseLinker, mô hình kế thừa cách khai thác text embedding, domain embedding, R-GCN và DistMult cho link prediction trên BKG. Từ HGDC, mô hình kế thừa tư tưởng dùng PPR để sinh mạng phụ trợ chứa tín hiệu gần cấu trúc toàn cục. Điểm khác biệt nằm ở cách tích hợp: thay vì dùng PPR để phân loại gene trên mạng phân tử, mô hình sử dụng PPR như một nhánh song song với R-GCN trong bài toán dự đoán liên kết đa quan hệ; đồng thời, hai nguồn embedding và hai nhánh đồ thị đều được hợp nhất bằng cổng học được thay vì phép trộn cố định.

Bên cạnh hai công trình chính, hướng nghiên cứu này cũng liên quan tới Knowledge Graph Embedding cho tái định hướng thuốc, GNN sinh học cho tương tác thuốc-gene, và các phương pháp kết hợp LLM với KG. So với KGE thuần, mô hình đề xuất tận dụng thêm văn bản và tri thức miền. So với GNN thuần, mô hình bổ sung embedding tiền huấn luyện và mạng phụ trợ toàn cục. So với transformer đa phương thức nặng, mô hình nhẹ hơn vì không fine-tune LLM mà chỉ dùng embedding tiền huấn luyện đông lạnh.

3. Method


Đồ thị tri thức y sinh được ký hiệu là $\mathcal{G} = (\mathcal{E}, \mathcal{R}, \mathcal{T})$, trong đó $\mathcal{E}$ là tập thực thể, $\mathcal{R}$ là tập quan hệ, và $\mathcal{T}$ là tập các bộ ba (h, r, t) đã quan sát. Bài toán dự đoán liên kết yêu cầu học hàm chấm điểm $f(h, r, t)$ sao cho các triple đúng có điểm cao hơn các triple sai. Link prediction có thể được diễn giải dưới ba dạng: dự đoán đuôi $(h, r, ?)$, dự đoán đầu $(?, r, t)$ hoặc dự đoán quan hệ $(h, ?, t)$.

Mỗi thực thể $e \in \mathcal{E}$ được mô tả bởi hai nguồn thông tin bổ sung cho cấu trúc đồ thị. Nguồn thứ nhất là embedding văn bản x_e^{text} , mã hóa ngữ nghĩa từ tên, mô tả sinh học hoặc thuộc tính văn bản của thực thể. Nguồn thứ hai là embedding tri thức miền x_e^{dom} , mã hóa kiến thức có cấu trúc từ ontology, UMLS Semantic Network hoặc không gian hyperbolic/Poincaré. Mục tiêu của mô hình là học biểu diễn nút $h_e \in \mathbb{R}^d$ và biểu diễn quan hệ $r_r \in \mathbb{R}^d$, sau đó dự đoán liên kết bằng bộ giải mã DistMult.

3.1. Kiến trúc tổng thể

Phương pháp đề xuất kế thừa khung FuseLinker: kết hợp embedding văn bản, embedding tri thức miền và mã hóa quan hệ bằng R-GCN. Điểm mở rộng nằm ở hai nhánh chính: cổng học nhất học được cho đặc trưng đa phương thức, và mạng phụ trợ PPR theo tinh thần HGDC. Toàn bộ mô hình gồm bốn khối chức năng.

Khối 1 – Khởi tạo đa phương thức. Mỗi thực thể được biểu diễn ban đầu bằng cách chiếu embedding văn bản và embedding tri thức



Hình 1: Kiến trúc tổng thể của mô hình Multimodal FuseLinker nâng cấp. Mô hình nhận đầu vào là BKG, text embeddings và domain embeddings; hợp nhất đa phương thức để tạo đặc trưng nút ban đầu; mã hóa song song bằng R-GCN trên đồ thị quan hệ gốc và PPR-GCN trên mạng phụ trợ; sau đó dùng gated fusion và DistMult decoder cho link prediction.

miền về cùng không gian ẩn, rồi hợp nhất qua FusionGate. Vector khởi tạo $h_e^{(0)}$ vừa mang thông tin ngữ nghĩa, vừa phản ánh cấu trúc phân cấp trong ontology y sinh, đồng thời làm điểm xuất phát cho cả hai nhánh mã hóa đồ thị.

Khối 2 – Mã hóa quan hệ bằng R-GCN. Từ tập train $\mathcal{T}_{\text{train}}$, ta xây đồ thị quan hệ có hướng $\mathcal{G}_{\text{rel}}$ và lan truyền $h_e^{(0)}$ qua các lớp R-GCN dạng residual. Nhánh này tổng hợp ngữ cảnh cục bộ qua các cạnh có kiểu quan hệ, giúp mô hình nắm bắt cấu trúc đa quan hệ đặc trưng của BKG.

Khối 3 – Mạng phụ trợ PPR. Song song với nhánh R-GCN, ta xây đồ thị phụ trợ $\mathcal{G}_{\text{ppr}}$ từ ma trận tương đồng cấu trúc PPR, rồi mã hóa cùng $h_e^{(0)}$ bằng GCN có trọng số cạnh. Nhánh này bổ sung tín hiệu toàn cục giữa các nút có thể không liên kề trên $\mathcal{G}_{\text{rel}}$ nhưng vẫn gần nhau về mặt cấu trúc.

Khối 4 – Gộp và chấm điểm. Biểu diễn từ hai nhánh được hợp nhất lần nữa bằng FusionGate, tạo vector nút cuối h_e . Cuối cùng, bộ giải mã DistMult tính điểm cho triple (h, r, t) phục vụ huấn luyện và đánh giá link prediction.

3.2. Khởi tạo biểu diễn nút đa phương thức

3.2.1. Nhánh văn bản

Embedding văn bản chiều cao d_t (ví dụ 768 với PubMedBERT) được nén về không gian ẩn d qua bộ mã hóa-giải mã, kế thừa thiết kế FuseLinker. Trong đó, encoder gồm hai tầng tuyến tính kèm BatchNorm, ReLU và Dropout. Trong huấn luyện link prediction, vector mã hóa được dùng làm đặc trưng chính; nhánh giải mã giữ lại để duy trì cấu trúc mô hình và có thể mở rộng cho mục tiêu tái tạo trong tương lai:

$$x_t = \text{LayerNorm}\left(W_E^{(2)} \text{Dropout}\left(\text{ReLU}\left(\text{BN}\left(W_E^{(1)} x\right)\right)\right)\right) \in \mathbb{R}^d, \quad (6)$$

$$\hat{x} = \text{ReLU}\left(W_D^{(2)} \text{ReLU}\left(\text{BN}\left(W_D^{(1)} x_t\right)\right)\right) \in \mathbb{R}^{d_{\text{text}}}. \quad (7)$$

3.2.2. Nhánh tri thức miền

Embedding Poincaré x_e^{dom} được chiếu vào cùng không gian ẩn thông qua MLP projector, cải tiến so với một tầng tuyến tính đơn trong FuseLinker gốc:

$$x_d = \text{LayerNorm}\left(W_2 \text{ReLU}(W_1 x_e)\right), \quad W_1 \in \mathbb{R}^{2d \times d_{\text{dom}}}, W_2 \in \mathbb{R}^{d \times 2d}. \quad (8)$$

MLP projector giúp mô hình học phép biến đổi phi tuyến giữa không gian Poincaré/domain và không gian ẩn Euclidean dùng cho R-GCN.

3.2.3. Hợp nhất có cổng

Thay vì dùng trung bình có trọng số cố định như Eq. (1), mô hình xây vector thống kê đa phương thức:

$$z_v = [x_t \| x_d \| |x_t - x_d| \| (x_t \odot x_d)] \in \mathbb{R}^{4d}. \quad (9)$$

Cổng hợp nhất được học theo từng nút và từng chiều ẩn:

$$g_e = \sigma\left(W_g^{(2)} \text{ReLU}(W_g^{(1)} z_v)\right) \in (0, 1)^d. \quad (10)$$

Để bảo toàn tính thần thiết kế FuseLinker, trọng số gốc w được dùng như một tiên nghiệm mềm:

$$g_e \leftarrow \frac{1}{2} g_e + \frac{1}{2} w \mathbf{1}. \quad (11)$$

Biểu diễn hợp nhất được tính bởi:

$$f = g_e \odot x_t + (1 - g_e) \odot x_d + \text{Residual}([x_t \| x_d]), \quad (12)$$

$$h_v^{(0)} = \text{Dropout}(\text{LayerNorm}(f) + e_{\text{id}}(v)), \quad e_{\text{id}} \in \mathbb{R}^d. \quad (13)$$

Embedding định danh nút $e_{\text{id}}(v)$ đóng vai trò residual theo ID, giúp giảm mất thông tin phân biệt giữa các thực thể.

3.3. Mã hóa cấu trúc quan hệ bằng R-GCN

Từ $\mathcal{T}_{\text{train}}$, ta xây đồ thị quan hệ $\mathcal{G}_{\text{rel}}$ với cạnh thuận và cạnh nghịch cho mỗi quan hệ r , tổng cộng $2|\mathcal{R}|$ loại quan hệ trong lớp tích chập. Chuẩn hóa theo bậc nút được áp dụng như trong FuseLinker và R-GCN.

Thay vì dùng lớp RelGraphConv đơn, mỗi lớp ẩn được cài đặt dưới dạng ResidualRelGraphConvBlock theo kiến trúc pre-LayerNorm:

$$\tilde{h}_v^{(\ell)} = \text{RGCN}\left(h_v^{(\ell-1)}, \text{rel_ids}, \text{norm}\right) + h_v^{(\ell-1)}, \quad (14)$$

$$\text{FFN}(h) = W_2 \text{ReLU}(W_1 h), \quad W_1 \in \mathbb{R}^{4d \times d}, W_2 \in \mathbb{R}^{d \times 4d}, \quad (15)$$

$$h_v^{(\ell)} = \text{FFN}\left(\text{LayerNorm}(\tilde{h}_v^{(\ell)})\right) + \tilde{h}_v^{(\ell)}. \quad (16)$$

Thiết kế này giúp huấn luyện sâu hơn, giảm suy thoái gradient và hạn chế over-smoothing so với R-GCN gốc. Khi có $L \geq 2$ lớp ẩn, biểu diễn nhánh quan hệ lấy trung bình các trạng thái ẩn theo tính thần Jumping Knowledge nhẹ:

$$h_v^{\text{rgcn}} = \frac{1}{L} \sum_{\ell=1}^L h_v^{(\ell)}. \quad (17)$$

Cơ chế này kết hợp thông tin cục bộ từ lớp nông và ngữ cảnh rộng hơn từ lớp sâu.

3.4. Mạng phụ trợ khuếch tán PPR

3.4.1. Động cơ

Trên KG y sinh, hai thực thể có vai trò chức năng tương tự có thể không kề nhau trên đồ thị gốc. R-GCN với 1–2 lớp chỉ tổng hợp tín hiệu từ lân cận gần, khó nắm bắt độ gần cấu trúc toàn cục. Đồng thời, đồ thị y sinh có tính dị phân (heterophilic): hàng xóm trực tiếp không nhất thiết tương tự về ngữ nghĩa. Theo HGDC, Personalized PageRank đo mức độ gần cấu trúc giữa các nút trên toàn đồ thị thông qua quá trình bước đi ngẫu nhiên có teleport.

Với ma trận kề đối xứng A và ma trận bậc D , ma trận chuyển tiếp chuẩn hóa được định nghĩa:

$$M = D^{-1/2} A D^{-1/2}, \quad D_{ii} = \sum_j A_{ij}. \quad (18)$$

Từ đó, ma trận tương đồng cấu trúc S được tính như Eq. (5). Mỗi giá trị S_{ij} đo độ gần cấu trúc giữa nút i và nút j trên phạm vi toàn đồ thị, không giới hạn trong hàng xóm một bước.

3.4.2. Làm thưa và xây đồ thị phụ trợ

Ma trận S thường dày đặc; áp dụng trực tiếp sẽ gây chi phí bộ nhớ và tính toán không khả thi trên KG lớn. Theo HGDC, ta làm thưa S bằng hai bước:

1. **Cắt ngưỡng** ε : đặt $S_{ij} = 0$ nếu $|S_{ij}| < \varepsilon$, đồng thời loại self-loop $S_{ii} = 0$.

$$\tilde{S}_{ij} = \begin{cases} S_{ij}, & |S_{ij}| \geq \varepsilon, \\ 0, & |S_{ij}| < \varepsilon. \end{cases} \quad (19)$$

2. Giữ top-k láng giềng mạnh nhất:

$$\tilde{S}_v = \text{TopK}_u(\tilde{S}_{vu}), \quad K = 50 \text{ (mặc định)}. \quad (20)$$

Từ $\tilde{S}$, ta xây đồ thị phụ trợ $\mathcal{G}_{\text{ppr}} = (\mathcal{E}, \mathcal{E}_{\text{ppr}})$, trong đó mỗi cạnh (v, u) mang trọng số $w_{vu} = \tilde{S}_{vu}$. Quan trọng là $\mathcal{G}_{\text{ppr}}$ chỉ được xây từ $\mathcal{T}_{\text{train}}$ để tránh rò rỉ thông tin kiểm tra.

3.4.3. PPR-GCN trên mạng phụ trợ

Với đặc trưng khởi tạo $h_e^{(0)}$, nhánh PPR lan truyền trên $\mathcal{G}_{\text{ppr}}$ qua L_{ppr} lớp PPRGraphConv có trọng số cạnh:

$$h_v^{\text{ppr}, k+1} = \text{ReLU} \left(\text{LayerNorm} \left(\sum_{u \in \mathcal{N}_{\text{ppr}}(v)} \tilde{S}_{uv} W^{(k)} h_u^{\text{ppr}, k} \right) \right). \quad (21)$$

Đầu ra của nhánh PPR là:

$$h_v^{\text{ppr}} = h_v^{\text{ppr}, L_{\text{ppr}}}. \quad (22)$$

Khác với R-GCN, nhánh này không phân biệt loại quan hệ mà tập trung vào độ gần cấu trúc toàn cục thông qua trọng số PPR.

3.5. Gộp hai nhánh song song

Biểu diễn cuối của mỗi nút được hợp nhất thích ứng giữa nhánh quan hệ cục bộ và nhánh khuếch tán toàn cục:

$$h_v^{\text{final}} = \text{FusionGate} \left(h_v^{\text{rgcn}}, h_v^{\text{ppr}} \right). \quad (23)$$

Dạng chi tiết tương tự gated fusion ở giai đoạn đầu vào:

$$h_v^{\text{final}} = g'_e \odot h_v^{\text{rgcn}} + (1 - g'_e) \odot h_v^{\text{ppr}} + \text{Residual}(\cdot). \quad (24)$$

Nhánh R-GCN giữ thông tin cạnh có kiểu quan hệ, còn nhánh PPR bổ sung tương đồng cấu trúc giữa các nút không liền kề. Thiết kế song song này mượn ý tưởng HGDC nhưng được điều chỉnh cho link prediction đa quan hệ trên KG y sinh.

3.6. Chấm điểm liên kết và hàm mất mát

Giữ nguyên bộ chấm điểm FuseLinker, mỗi quan hệ r có embedding $R_r \in \mathbb{R}^{d \times d}$ học được. Điểm của triple (s, r, o) được tính theo DistMult:

$$\text{score}(s, r, o) = \langle h_s^{\text{final}}, R_r, h_o^{\text{final}} \rangle = \sum_i h_{s,i}^{\text{final}} R_{r,i} h_{o,i}^{\text{final}}. \quad (25)$$

Với mini-batch gồm triple dương và triple âm tạo bởi negative sampling, hàm mất mát là binary cross-entropy with logits kèm regularization L2:

$$\mathcal{L} = \text{BCEWithLogits}(\text{score}, y) + \lambda \left(\|H\|_2^2 + \|R\|_2^2 \right). \quad (26)$$

Gradient clipping được áp dụng để ổn định huấn luyện.

4. Experimental Results

4.1. Thiết lập thực nghiệm

Thực nghiệm so sánh mô hình đề xuất (*Upgrade*) với baseline FuseLinker (*Base*) trên bốn BKG: SuppKG, ADInt, KEGG50K và Hetionet. Với mỗi tập, mô hình được chạy với năm nguồn đặc trưng văn bản khác nhau: PubMedBERT, BERT, Flan-T5, LLaMA2 và MedLLaMA/PMC-LLaMA. Toàn bộ quy trình huấn luyện/đánh giá được giữ nguyên để so sánh công bằng.

Các độ đo sử dụng gồm MR (Mean Rank, càng thấp càng tốt), MRR (Mean Reciprocal Rank, càng cao càng tốt), Hits@1, Hits@3, Hits@10 (càng cao càng tốt) và AUROC. MR và MRR phản ánh chất lượng xếp hạng; Hits@K phản ánh khả năng đưa triple đúng vào nhóm ứng viên đầu; AUROC phản ánh khả năng phân biệt cạnh dương/âm trên toàn bộ ngưỡng.

4.2. Kết quả xếp hạng trên từng tập dữ liệu

Kết quả trên bốn bảng cho thấy mô hình đề xuất cải thiện MRR và Hit@1 trên hầu hết cấu hình. Mức cải thiện rõ nhất xuất hiện ở ADInt, nơi MR giảm mạnh và Hit@1 tăng từ khoảng 0.56–0.66 lên khoảng 0.85 đối với các cấu hình có kết quả Upgrade. SuppKG cũng cho cải thiện ổn định với MRR tăng khoảng 0.085–0.107. KEGG50K có mức tăng nhỏ hơn do baseline đã gần bão hòa, nhưng Upgrade vẫn cải thiện MRR và Hit@1 trên cả năm nguồn embedding. Trên Hetionet, MRR tăng rõ ở PubMedBERT, BERT, Flan-T5 và MedLLaMA; cấu hình LLaMA2 có cải thiện MRR nhỏ hơn nhưng các chỉ số Hit@K vẫn tăng.

4.3. Kết quả AUROC

Kết quả AUROC cho thấy mô hình đề xuất đạt AUROC cao hơn baseline trên hai trong ba tập dữ liệu được báo cáo đầy đủ: SuppKG và KEGG50K. Mức tăng trung bình lớn nhất quan sát được trên SuppKG (ΔAUROC khoảng +0.0073), nhất quán với xu hướng cải thiện mạnh ở MRR và Hits@K. Trên KEGG50K, mức tăng nhỏ hơn nhưng đều đặn trên cả năm embedding, phù hợp với hiệu ứng trần khi baseline đã rất cao.

Điểm đáng lưu ý là trên Hetionet, AUROC trung bình của Upgrade giảm nhẹ so với Base (0.8648 xuống 0.8595), trong khi các chỉ số xếp hạng vẫn được cải thiện rõ. Điều này cho thấy AUROC và MRR/Hits@K phản ánh hai khía cạnh khác nhau: AUROC đo khả năng phân biệt cạnh dương/âm trên toàn bộ ngưỡng, còn MRR và Hits@K đo chất lượng xếp hạng cạnh đúng trong nhóm ứng viên đầu. Với ứng dụng tái định hướng thuốc, chất lượng top ranking thường có ý nghĩa trực tiếp hơn vì nhà nghiên cứu chỉ kiểm tra một số ứng viên xếp hạng cao nhất.

Bảng 7: Mức cải thiện MRR trung bình theo tập dữ liệu.

Tập dữ liệu	$\Delta\text{MRR TB}$	MRR Base $\rightarrow$ Upgrade
ADInt	$\approx +0.17$	$\sim 0.68\text{--}0.76 \rightarrow \sim 0.90$
Hetionet	$\approx +0.11$	$\sim 0.48\text{--}0.51 \rightarrow \sim 0.59\text{--}0.61$
SuppKG	$\approx +0.10$	$\sim 0.71\text{--}0.73 \rightarrow \sim 0.81\text{--}0.82$
KEGG50K	$\approx +0.015$	$\sim 0.96\text{--}0.98 \rightarrow \sim 0.98\text{--}0.99$

5. Discussion

5.1. Cải thiện nhất quán trên nhiều tập dữ liệu và embedding

Kết quả thực nghiệm cho thấy mô hình đề xuất vượt baseline FuseLinker trên hầu hết các cấu hình về MR, Hits@1, Hits@3, Hits@10 và MRR. Điều quan trọng là mức cải thiện này không phụ thuộc tuyệt đối vào việc chọn mô hình sinh đặc trưng văn bản. Dù dùng BERT đa dụng, mô hình y sinh chuyên biệt như PubMedBERT/MedLLaMA, hay LLM tổng quát như LLaMA2/Flan-T5, Upgrade nhìn chung vẫn mang lại lợi ích đáng kể. Điều này cho thấy nguồn cải thiện đến từ kiến trúc: gated fusion, nhánh phụ trợ PPR và backbone residual, chứ không chỉ từ một nguồn embedding may mắn.

5.2. Mức cải thiện phụ thuộc vào đặc điểm đồ thị

Biên độ cải thiện thay đổi rõ giữa các tập, phù hợp với động lực thiết kế. ADInt và Hetionet là hai đồ thị khó hơn, có MRR baseline thấp hơn và MR cao hơn. Trên ADInt, MR giảm gần một nửa ở các cấu hình có kết quả Upgrade, còn Hit@1 tăng mạnh. Đây là dấu hiệu cho thấy tín hiệu độ gần cấu trúc toàn cục từ PPR đặc biệt hữu ích khi lân cận cục bộ nhiều hoặc không đủ thông tin.

SuppKG cho cải thiện ổn định, với MRR tăng khoảng 0.10 và Hit@1 tăng từ khoảng 0.60 lên 0.74. Điều này cho thấy gated fusion và PPR-GCN có thể bổ sung tốt cho nhau trên đồ thị có độ khó trung bình. KEGG50K thể hiện hiệu ứng trần: baseline đã rất cao, nên dư địa cải thiện nhỏ. Tuy vậy, Upgrade vẫn không làm giảm hiệu năng và còn cải thiện nhẹ MRR, chứng tỏ nhánh phụ trợ không gây hại ngay cả khi bài toán gần bão hòa.

5.3. Cải thiện tập trung ở các vị trí xếp hạng đầu

Một quan sát đáng chú ý là Hit@1 thường cải thiện mạnh hơn Hit@10. Nói cách khác, mô hình không chỉ kéo các đáp án đúng vào top-K, mà còn đẩy chúng lên vị trí đầu. Đặc tính này đặc biệt quan trọng cho ứng dụng tái định hướng thuốc, nơi người dùng thường chỉ kiểm chứng một số ứng viên xếp hạng cao nhất do chi phí thí nghiệm cao.

5.4. Tăng tính bền vững với lựa chọn embedding

Ngoài nâng điểm tuyệt đối, Upgrade còn thu hẹp khoảng cách giữa các nguồn embedding khác nhau. Cống hợp nhất học được cho phép mô hình điều chỉnh mức độ tin cậy của từng nguồn theo từng nút, thay vì áp một tỉ lệ trộn cố định. Nhờ đó, mô hình ít nhạy cảm hơn với chất lượng tuyệt đối của đặc trưng văn bản ban đầu. Đây là lợi

Bảng 2: SuppKG: FuseLinker (Base) vs mô hình đề xuất (Upgrade).

Embedding	Mô hình	MR↓	Hit@1↑	Hit@3↑	Hit@10↑	MRR↑	ΔMRR
PubMedBERT	Base	2.9677	0.6043	0.8026	0.9458	0.7220	–
	Upgrade	2.3645	0.7358	0.8755	0.9643	0.8166	+0.0946
BERT	Base	2.8912	0.6131	0.8076	0.9486	0.7281	–
	Upgrade	2.3277	0.7297	0.8754	0.9641	0.8132	+0.0851
Flan-T5	Base	3.2079	0.5991	0.7895	0.9355	0.7138	–
	Upgrade	2.4040	0.7371	0.8750	0.9613	0.8169	+0.1031
LLaMA2	Base	3.1212	0.6023	0.7934	0.9396	0.7173	–
	Upgrade	2.3005	0.7404	0.8679	0.9644	0.8196	+0.1023
MedLLaMA	Base	3.0094	0.5966	0.7972	0.9451	0.7162	–
	Upgrade	2.1513	0.7416	0.8849	0.9716	0.8235	+0.1073

Bảng 3: ADInt: FuseLinker (Base) vs mô hình đề xuất (Upgrade).

Embedding	Mô hình	MR↓	Hit@1↑	Hit@3↑	Hit@10↑	MRR↑	ΔMRR
PubMedBERT	Base	4.0756	0.5644	0.7576	0.9056	0.6823	–
	Upgrade	1.8764	0.8492	0.9331	0.9766	0.8964	+0.2141
BERT	Base	3.0491	0.6448	0.8246	0.9423	0.7497	–
	Upgrade	1.7748	0.8529	0.9376	0.9800	0.9002	+0.1505
Flan-T5	Base	3.1992	0.6456	0.8291	0.9367	0.7484	–
	Upgrade	1.7534	0.8503	0.9367	0.9804	0.8985	+0.1501
LLaMA2	Base	2.9706	0.6587	0.8361	0.9448	0.7611	–
	Upgrade	–	–	–	–	–	–
MedLLaMA	Base	3.4033	0.6242	0.8065	0.9308	0.7321	–
	Upgrade	–	–	–	–	–	–

Bảng 4: KEGG50K: FuseLinker (Base) vs mô hình đề xuất (Upgrade).

Embedding	Mô hình	MR↓	Hit@1↑	Hit@3↑	Hit@10↑	MRR↑	ΔMRR
PubMedBERT-768	Base	1.0630	0.9710	0.9945	0.9990	0.9828	–
	Upgrade	1.0568	0.9800	0.9950	0.9988	0.9878	+0.0050
BERT	Base	1.0795	0.9610	0.9927	0.9993	0.9772	–
	Upgrade	1.0372	0.9830	0.9975	0.9995	0.9901	+0.0129
Flan-T5	Base	1.0948	0.9585	0.9915	0.9987	0.9738	–
	Upgrade	1.0532	0.9832	0.9965	0.9990	0.9899	+0.0161
LLaMA2	Base	1.0900	0.9568	0.9922	0.9988	0.9744	–
	Upgrade	1.0492	0.9772	0.9967	0.9992	0.9868	+0.0124
MedLLaMA	Base	1.1578	0.9318	0.9848	0.9980	0.9588	–
	Upgrade	1.0512	0.9827	0.9952	0.9988	0.9893	+0.0305

Bảng 5: Hetionet: FuseLinker (Base) vs mô hình đề xuất (Upgrade).

Embedding	Mô hình	MR↓	Hit@1↑	Hit@3↑	Hit@10↑	MRR↑	ΔMRR
PubMedBERT-768	Base	7.2395	0.3269	0.5433	0.7841	0.4750	–
	Upgrade	5.4801	0.4771	0.6693	0.8542	0.6025	+0.1275
BERT	Base	6.4086	0.3498	0.5746	0.8148	0.5006	–
	Upgrade	5.3609	0.4650	0.6629	0.8550	0.5940	+0.0934
Flan-T5	Base	6.2233	0.3603	0.5845	0.8239	0.5103	–
	Upgrade	5.1511	0.4893	0.6823	0.8643	0.6139	+0.1036
LLaMA2	Base	6.4896	0.3451	0.5683	0.8114	0.4958	–
	Upgrade	5.2884	0.4747	0.6719	0.8612	0.5288	+0.0330
MedLLaMA	Base	6.3479	0.3516	0.5761	0.8172	0.5023	–
	Upgrade	5.8259	0.4767	0.6648	0.8466	0.5996	+0.0973

Bảng 6: AUROC theo từng nguồn đặc trưng văn bản trên SuppKG, Hetionet và KEGG50K.

Tập dữ liệu	Mô hình	PubMedBERT	Flan-T5	LLaMA2	BERT	MedLLaMA/PMC-LLaMA	Trung bình	ΔAUROC
SuppKG	Base	0.9149	0.9144	0.9114	0.9149	–	0.9128	–
	Upgrade	0.9213	0.9175	0.9231	0.9213	0.9085	0.9173	+0.0073
Hetionet	Base	0.8652	0.8583	0.8657	0.8593	–	0.8648	–
	Upgrade	0.8450	0.8576	0.8644	0.8650	0.8657	0.8595	-0.0053
KEGG50K	Base	0.9802	0.9808	0.9810	0.9811	–	0.9814	–
	Upgrade	0.9834	0.9870	0.9873	0.9845	0.9865	0.9857	+0.0043

thể thực tiễn vì lựa chọn mô hình sinh embedding thường tốn kém và phụ thuộc lĩnh vực.

5.5. Thảo luận kết quả AUROC

AUROC bổ sung một góc nhìn quan trọng cho các nhận xét từ MR/MRR/Hits@K. Trên SuppKG và KEGG50K, AUROC tăng đồng đều cho thấy mô hình cải thiện cả khả năng phân biệt cạnh dương/âm. Trên Hetionet, AUROC giảm nhẹ trong khi xếp hạng top-K cải thiện; điều này gợi ý rằng PPR có thể đưa vào một số tín hiệu toàn cục làm nhiễu phân biệt ngưỡng tổng thể, nhưng vẫn hữu ích cho ranking các ứng viên đứng lên vị trí cao. Trong bối cảnh drug repurposing, hai nhóm chỉ số cần được xem là bổ sung nhau thay vì thay thế nhau.

5.6. Phân tích đóng góp của từng thành phần

Dựa trên thiết kế và xu hướng kết quả, lợi ích của mô hình có thể được quy cho ba thành phần bổ trợ nhau:

1. **Gated fusion** thay trung bình trọng số cố định, giải quyết hạn chế trộn cứng nhắc của FuseLinker và tăng tính bền vững trên nhiều nguồn embedding.
2. **Nhánh PPR-GCN** bổ sung độ gần cấu trúc toàn cục, đóng góp lớn nhất trên các đồ thị khó hoặc nhiễu như ADInt và Hetionet, nơi thông tin cục bộ không đủ.
3. **Backbone residual + LayerNorm + Jumping Knowledge** ổn định huấn luyện khi tăng độ sâu, giúp khai thác đồng thời tín hiệu cục bộ và toàn cục mà không bị over-smoothing quá mạnh. Nhờ nguyên tắc thoái lui an toàn, khi tắt nhánh PPR mô hình trở về

dạng baseline cải tiến. Điều này thuận lợi cho ablation study để định lượng riêng từng thành phần trong nghiên cứu tiếp theo.

5.7. Hạn chế và hướng phát triển

Mô hình vẫn còn một số hạn chế. Thứ nhất, mạng phụ trợ PPR hiện được dựng từ ma trận không phân biệt loại quan hệ, nên tín hiệu cấu trúc toàn cục có thể mất thông tin relation-aware. Hướng tiếp theo là PPR theo từng loại quan hệ hoặc meta-path-aware PPR. Thứ hai, chi phí tính toán của PPR trên đồ thị lớn cần tiếp tục tối ưu. Có thể dùng power iteration dạng streaming thưa hoặc approximate PPR để giảm bộ nhớ. Thứ ba, một vài cấu hình còn thiếu kết quả, ví dụ LLaMA2 và MedLLaMA trên ADInt; cần bổ sung để hoàn thiện so sánh. Cuối cùng, cần khảo sát độ nhạy của các siêu tham số c , ϵ , top-k và trọng số tiên nghiệm mềm w .

Tổng thể, các kết quả khẳng định rằng việc kết hợp hợp nhất đa nguồn thích ứng với tín hiệu cấu trúc toàn cục từ mạng phụ trợ PPR mang lại cải thiện nhất quán, bền vững và đặc biệt hiệu quả trên các BKG khó. Thiết kế này phù hợp với mục tiêu nâng cao chất lượng dự đoán liên kết phục vụ tái định hướng thuốc và khám phá giả thuyết y sinh.

Tài liệu

[1] Y. Xiao, S. Zhang, H. Zhou, M. Li, H. Yang, R. Zhang, “FuseLinker: Leveraging LLM’s pre-trained text embeddings and domain knowledge to enhance GNN-based link prediction on biomedical knowledge graphs,” *Journal of Biomedical Informatics*, 158, 104730, 2024. Link: <https://doi.org/10.1016/>

- j.jbi.2024.104730
- [2] T. Zhang, S.-W. Zhang, M.-Y. Xie, Y. Li, “A novel heterophilic graph diffusion convolutional network for identifying cancer driver genes,” *Briefings in Bioinformatics*, 24(3), bbad137, 2023. Link: <https://doi.org/10.1093/bib/bbad137>
 - [3] M. Schlichtkrull, T. N. Kipf, P. Bloem, R. van den Berg, I. Titov, M. Welling, “Modeling relational data with graph convolutional networks,” in *European Semantic Web Conference*, Springer, 2018, pp. 593–607. Link: https://doi.org/10.1007/978-3-319-93417-4_38
 - [4] D. S. Himmelstein et al., “Systematic integration of biomedical knowledge prioritizes drugs for repurposing,” *eLife*, 6, e26726, 2017. Link: <https://doi.org/10.7554/eLife.26726>
 - [5] D. Schutte et al., “Discovering novel drug-supplement interactions using SuppKG generated from the biomedical literature,” *Journal of Biomedical Informatics*, 131, 104120, 2022. Link: <https://doi.org/10.1016/j.jbi.2022.104120>
 - [6] S. Zheng et al., “PharmKG: a dedicated knowledge graph benchmark for biomedical data mining,” *Briefings in Bioinformatics*, 22, bbaa344, 2020. Link: <https://doi.org/10.1093/bib/bbaa344>
 - [7] M. Kanehisa, S. Goto, “KEGG: Kyoto encyclopedia of genes and genomes,” *Nucleic Acids Research*, 28(1), 27–30, 2000. Link: <https://doi.org/10.1093/nar/28.1.27>
 - [8] B. Yang, W. Yih, X. He, J. Gao, L. Deng, “Embedding entities and relations for learning and inference in knowledge bases,” in *ICLR*, 2015. Link: <https://arxiv.org/abs/1412.6575>
 - [9] J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *NAACL-HLT*, 2019. Link: <https://arxiv.org/abs/1810.04805>
 - [10] Y. Gu et al., “Domain-specific language model pretraining for biomedical natural language processing,” *ACM Transactions on Computing for Healthcare*, 3, 2021. Link: <https://doi.org/10.1145/3458754>
 - [11] H. W. Chung et al., “Scaling instruction-finetuned language models,” *Journal of Machine Learning Research*, 25, 2024. Link: <https://jmlr.org/papers/v25/23-0870.html>
 - [12] H. Touvron et al., “Llama 2: Open foundation and fine-tuned chat models,” arXiv:2307.09288, 2023. Link: <https://arxiv.org/abs/2307.09288>
 - [13] C. Wu et al., “PMC-LLaMA: Further finetuning LLaMA on medical papers,” arXiv:2304.14454, 2023. Link: <https://arxiv.org/abs/2304.14454>
 - [14] M. Nickel, D. Kiela, “Poincaré embeddings for learning hierarchical representations,” in *NeurIPS*, 2017. Link: <https://arxiv.org/abs/1705.08039>
 - [15] I. Balazevic, C. Allen, T. Hospedales, “Multi-relational Poincaré graph embeddings,” in *NeurIPS*, 2019. Link: <https://arxiv.org/abs/1905.09791>
 - [16] O. Bodenreider, “The unified medical language system (UMLS): integrating biomedical terminology,” *Nucleic Acids Research*, 32, D267–D270, 2004. Link: <https://doi.org/10.1093/nar/gkh061>
 - [17] Y. Li et al., “A survey of graph meets large language model: Progress and future directions,” arXiv:2407.05816, 2024. Link: <https://arxiv.org/abs/2407.05816>
 - [18] S. Pan et al., “Unifying large language models and knowledge graphs: A roadmap,” *IEEE Transactions on Knowledge and Data Engineering*, 36, 3580–3599, 2024. Link: <https://arxiv.org/abs/2306.08302>